

仲恺农业工程学院

毕 业 论 文

基于网络爬虫的热点话题网站设计与实现

姓 名	周广锋
院（系）	计算科学学院
专业班级	信息与计算科学 162 班
学 号	201621314232
指导教师	肖爱平 伍碧林（校外）
职 称	实验师 工程师
论文答辩日期	2020 年 5 月 9 日

仲恺农业工程学院教务处制

Design and Implementation of Hot Topic Website Based on Web Crawler

Zhou Guangfeng

College of Computational Science
Zhongkai University of Agriculture and Engineering
Guangzhou, China

Supervisor: Experimentalist Xiao Aiping
Engineer Wu Bilin (Extramural Tutor)

学生承诺书

本人郑重承诺：所呈交的毕业论文（设计）是本人在导师的指导下独立进行研究所取得的成果。除了文中已用特别标志加以标记的引述内容之外，本论文（设计）不含有任何其他个人或集体已经发表或撰写的研究成果。对本文研究做出过重要贡献的个人或集体，均已在文中以明确的方式标明。若在毕业论文（设计）的各项检查、评比中被发现有抄袭、剽窃或其他的违规行为，本人愿按学校有关规定接受处理，并承担相应的法律责任。

学生（签名）：

2020 年 5 月 7 日

摘 要

随着互联网的不断发展，人们获取信息的来源也越来越广。获取新闻信息已经不只是单纯的从传统的电视媒介中获取，越来越多的网络媒体也提供了新闻资讯。

本项目通过 Python 中的 Scrapy 框架，爬取各大新闻网站的新闻资讯，存入 MySQL 数据库中。通过 TextRank 算法，对新闻内容进行关键字的提取。使用 Spring Boot 框架作为后端框架，Vue.js 作为前端框架，把新闻内容以及其关键字展现在网页上。用户能快速的鉴别是否属于自己所感兴趣的内容。用户可以收藏和评论文章，通过收藏文章，用户可以通过收藏夹重新浏览文章。

关键词：爬虫 新闻 Spring Boot TextRank MySQL

Abstract

With the continuous development of the Internet, people have more and more sources of information. Access to news information is not only from the traditional television media, more and more network media also provide news information.

Through the Scrapy framework in Python, this project crawls news information from various news websites and stores it in MySQL database. TextRank algorithm is used to extract keywords from news content. Using the Spring Boot framework as the back-end framework and vue.js as the front-end framework, news content and its keywords are displayed on the web page. Users can quickly identify whether they are interested in the content. Users can bookmark and comment on articles. By bookmarking articles, users can re-view articles through favorites

Key words: crawler; news; Spring Boot; TextRank; MySQL

目 录

1 前言	1
1.1 研究目的与意义	1
1.2 研究现状	1
1.3 论文结构	2
2 可行性分析	3
2.1 技术可行性	3
2.2 经济可行性	3
2.3 用户操作可行性	4
2.4 法律可行性	4
2.5 可行性分析结论	4
3 系统需求分析	4
3.1 用户需求分析	4
3.2 管理员需求分析	6
3.3 性能需求分析	7
3.4 其他需求分析	7
4 概要设计	8
4.1 系统结构设计	8
4.2 功能模块设计	8
4.3 数据库设计	11
5 详细设计	16
5.1 新闻爬虫详细设计	16
5.2 关键字提取流程	18
5.3 用户登录注册操作详细设计	19
6 系统实现	22
6.1 软件开发说明	22
6.2 操作系统界面和功能实现	23
6.3 个人界面	27
6.4 管理员界面	28

7 结语	30
参考文献	31
致谢	32

1 前言

1.1 研究目的与意义

自从互联网的普及以后,传统新闻发生了巨大的变化,新闻传播媒介从传统的电视、报纸和杂志等等的传统渠道,转向了互联网,新闻呈现的方式也变得多元化。互联网的出现,促进了传统媒体的转变,新闻从原本每日一发到现在的紧贴实时事件,实时发文;从原来传统的文字,图片到现在短视频、音频等。同时,得益于互联网的实时交互,每个人都可以成为媒体,“自媒体”就是这么诞生,每个人都有“话筒”。在纷繁嘈杂的互联网环境中,每时每刻都会有成千上万的新闻报道发出。与传统新闻传播相比,新媒体传播平台上的网络新闻更具时代性^[1]。在众多的互联网新闻平台上用户无法确定新闻的时效性和真实性。用户的时间也是有限的,无法挑出或筛选出自己所喜欢的内容。与此同时,每一位用户看到的新闻标题五花八门,有一些编辑人员为了吸引用户的点击,编写虚假或者夸张的标题,也就是所谓“标题党”。

所以,在此背景下。本设计构建一个新闻内容展示平台,为了解决新闻内容众多而且无法识别的问题。本系统设计一个爬虫,用于爬取国内大型新闻平台中的新闻内容,保证了新闻时效性和真实性。爬取到新闻后,系统将会对新闻正文进行关键字提取,提前把内容的关键字展现给用户,让用户根据新闻内容的关键字,自行选择是否打开该新闻,以达到节省用户时间的作用。新闻内容也会按照时间以及原平台位置先后排列,展现给用户。用户也可以根据自己所喜欢的关键字,搜索相应的新闻。在新闻内容方面,本设计添加了新闻收藏、喜爱功能和评论功能,用户可以对自己所喜欢的新闻进行收藏、评论和点赞。平台会根据用户的收藏和评论,对新闻热门的新闻进行排序,展示给其他用户,用户由此知道目前比较热门的新闻。另外,平台也会根据每一篇新闻的关键字,统计出现最多的关键字,并且展示给用户。让用户了解最近新闻报道的趋势。

1.2 研究现状

在网络平台方面,基本上市面上比较出名的新闻平台都是用人工标记方法,对每一篇新闻报道进行关键字的提取。早期的新闻采集大多靠人工去搜索和整理,直到网络爬虫技术的出现才得以解放人力,大大提高了新闻的采集速度。为了更加快速准确地抓取网页,Cho 等人在爬虫中引入了网页抓取策略的概念^[2]。

在爬虫的研究方面,将爬虫分为了四种类型,分别有通用网络爬虫,聚焦网络爬虫,增量式网络爬虫以及 Deep Web 爬虫。一般来说,对于爬取新闻内容的爬虫是属于聚焦网络爬虫,聚焦于某一个类型或者话题。

基本上各个搜索引擎公司都会有自己的爬虫,并且技术发展成熟。以百度资讯为例,是一类以新闻资讯为目标的搜索引擎,本质就是爬虫加上索引组成。在爬虫方面,百度爬虫会遵守 robots 协议,百度资讯几乎每时每刻都会在各个网站上爬取,对网站进行质量排序,优先爬取高质量的网站。爬取网站的同时,同时为网站留下一个“快照”,以便于追溯原网站。百度爬虫的爬取策略属于深度优先,以抓取页面为起点,不断的抓取同一个网页的其他 URL 地址。

在关键字提取研究方面,分为了两种流派。一种是基于统计流派,思路为定义关键字指标,对文章的内容进行分词,计算关键字指标,按照指标从大到小排列,指标大的关键字。其中影响力最大的两个是:TF-IDF 指标和 PageRank 指标。TF-IDF 基于词袋模型^[3],基于 TF-IDF 方法,徐文海等人提出一种基于向量空间模型的中文关键字提取算法,通过该方法实现了中文文献的关键词自动抽取^[4]。PageRank 指标,基于网络模型,把文章表示成网络的结构,网络中的节点表示为词汇,节点之间的边为词汇之间位置的邻接关系。考虑到了文章内词汇的顺序。另一种流派是规则流派,对一个词汇进行二元分类的任务,就是定义一个词汇是否为一个关键字。把问题变成了一个预测问题。规则通过人工指定,也可以通过机器学习的方法获得。而最近比较火热的深度学习,也成为了提取关键字的一个发展方向,通过多层的神经网络来提取抽象的词汇特征,不过深度学习中的词汇依然需要人工标注。

1.3 论文结构

第一部分是前言,讲述本论文的研究背景、研究目的与意义和研究现状,展示出新闻平台出现的意义,介绍了现在爬虫的发展现状以及关键字提取技术的发展现状。

第二部分是可行性分析,通过系统定义进一步对系统进行可行性分析,系统的可行性分析主要包括技术可行性、经济可行性和操作可行性和系统运行可行性分析进行研究分析。通过可行性研究,表明基于爬虫的热点新闻网站建设是可行的。

第三部分是需求分析,针对系统的用户和管理员的需求进行深度分析,该部分分别指出每一种角色需要实现什么功能以及功能中的一些细节。

第四章是概要设计,概要设计是在需求分析之上进行设计的,对系统进行更深一层的分析设计,用例图展示软件的结构和各个组件之间的关系,确定系统中每个模块的划分以及数据库的设计。

第五章是详细设计,本部分是在概要设计的基础上对系统进行更深一层的设计,通过设计原理详细描述以及业务流程图和数据流程图来展示系统的设计,完善系统。

第六章是系统实现，本部分主要就是展示新闻平台中部分操作，其中包括了对新闻报道的操作、管理员的操作、爬虫操作以及对新闻内容关键字提取的操作。

第七章是结语，本部分对论文整体做出总结，总结出本次毕业设计使用到的技术，描述有哪些功能，以及有哪些缺陷需要以后完善。

2 可行性分析

可行性分析的目的是确定开发本系统在技术方面能否达到要求，在用户的操作方式方面能否满足功能目标，在经济性等方面有没有问题，以及能否按时完成等，为系统开发提出专业意见以及依据，得出开发该系统的可行性，帮助决定是否要开发该系统。

2.1 技术可行性

技术可行性是根据系统中各个模块的功能目标和性能需求等，从技术层面研究分析，确认技术是否可行，下面将进行技术可行性分析：

（1）利用现有的技术，功能目标能否达到

本系统中爬虫部分是使用的是 Python 语言，使用了 Scrapy 框架简化爬取的流程。在处理新闻报道内容上，使用了 jieba 组件，用于分词，便于计算。数据库使用的是 MySQL，一款非常经典的开源关系库数据库。后端开发是使用 Java 语言，使用的是 Spring Boot 框架开发。在前端方面，使用的是 Vue.js 框架，简化了开发流程。以上都是基于 Windows 操作系统环境下进行软件开发。

（2）对开发人员的要求能否满足

本系统分为了三个部分进行开发，分别是爬虫部分、前端部分和后端部分，他们之间通过 API 进行程序的交互。其中爬虫部分使用 Python 属于脚本语言，非常容易上手。后端部分 Spring Boot 的“约定大于配置”思想让配置变得非常简单，技术成熟，方便 Web 程序员开发。前端部分的 Vue.js 也是一款比较大众的框架，只要熟悉 HTML、CSS 和 JavaScript 语言就容易上手此框架。所以，所运用的技术都是市面上普遍成熟的技术。完全满足了项目开发的技术要求。

2.2 经济可行性

本系统中，除了爬虫部分和后端部分使用的 IDE 属于收费软件，其他都是开源免费的软件，而收费的 IDE 可以使用 VS Code 代替，这样在开发过程中就可以做到 0 成本。同时由于开发人员只有自己一个人，也不需要付额外的人工成本。最后就是需要购买服务器部署项目，这个需要多个服务器，一到两个服务器负责部署爬虫，另外一个服务器负责部署前后端以及数据库，费用总和大约在 30 元/月，研究经费在能力范围内，所以

经济可行

2.3 用户操作可行性

对于用户而言，该系统的指导简介友好，不需要其他的专业知识，根据网页的指示就可以满足用户的需求，所以用户操作上也不存在着问题。

2.4 法律可行性

本系统中使用的框架、IDE 和 MySQL 数据库皆是免费开源，各项操作都复合开源协议的标准，只用于研究实验，非商业用途。而在爬虫方面。对于爬虫技术本身来说，技术创新具有推动社会经济发展的积极意义，但是，技术也存在被恶意使用的问题^[5]。爬取的数据都是网页公开的新闻报道，遵守《中华人民共和国网络安全法》。同时，获得的数据不用作于商业用途，所以法律可行。

2.5 可行性分析结论

可行性研究结论：可行。

可行性研究说明：通过以上各方面的分析，分别在法律、技术、经济、用户操作上，都是属于可行操作。所以开发此系统是可行的。

3 系统需求分析

3.1 用户需求分析

3.1.1 游客需求分析

在没有注册之前，所有的用户都属于游客用户，而对于游客用户来说，要展现新闻平台最基本的功能给游客。例如新闻展示等等。

(1) 新闻浏览功能

作为一个新闻平台，最重要的功能就是展示新闻。所以，当游客进入首页，可以看到新闻，新闻是按照时间降序排列在首页中，展示了新闻的简略内容，包括了标题、作者、出稿时间以及内容统计出来的关键字。

(2) 新闻详情浏览功能

当用户或者游客对一则新闻感兴趣的时候，可以点击进去到新闻详情页，到了新闻详情页，游客用户能够看到的是正文内容，同时看到其他用户的评论以及该新闻的点赞数，当然也可以通过链接，直接去到原本的地址浏览新闻内容。

(3) 点赞功能

当一篇新闻得到游客的喜欢时，可以通过点赞功能给文章点赞，为文章点赞能够提高文章的热度，提高文章在排行榜出现的可能。

(4) 关键字浏览功能

作为本次系统设计的主要功能，游客可以通过首页的关键字排行榜，查看最近新闻报道的高频词，也可以通过浏览每一个新闻简略内容卡中的关键字，提前得知该篇新闻的关键字。

(5) 搜索功能

游客可以通过搜索功能，根据给出的检索字词检索出包含对应检索字词新闻标题、新闻作者、关键词等等，游客就可以快速的得到他想要的新闻内容。

(6) 注册和登录功能

游客可以通过注册功能，成为该平台中的一名用户，享受用户的权利。在注册中，需要填入自己的用户名、邮箱以及密码。注册完成以后，跳转到登录界面。登录则需要用户名和密码即可。

(7) 浏览排行榜功能

除了浏览新闻内容以外，还可以查看排行榜，排行榜上包括了收藏最多的新闻，点赞最多的新闻，评论最多的新闻，以及出现最多的关键字，这些都是根据用户的点赞、评论等等统计出来的。

(8) 文章推荐功能

在游客看完一篇新闻报道后，可以通过下方的文章推荐，查看类似或者热门的文章。

(9) 查看其它用户功能

通过查看用户功能，可以看到其他用户的信息、个性签名，找到与你类似用户，通过他的收藏，看到更多的新闻。

具体功能如图 1 游客用例图所示




图 1 游客用例图

3.1.2 用户功能

(1) 评论功能

用户可以通过评论功能，新闻时事进行评论。用户也可以看到其他用户的评论，当然，评论也可以被其他用户看到。

(2) 收藏功能

用户使用收藏功能，可以收藏自己喜欢的新闻内容，以后可以在个人中心查看回自己收藏过的文章。

(3) 修改个人资料功能

用户可以通过修改个人资料，把自己的资料展现给其他用户。

(4) 修改密码功能

当用户觉得自己的账号密码不安全的时候，可以通过修改密码，以确保账号安全。具体功能如图 2 用户用例图所示。




图 2 用户用例图

3.2 管理员需求分析

(1) 用户管理功能

作为管理员的基本职能，就是要管理其他用户。管理其他用户的状态。控制其他用户的登录权限。

(2) 爬虫管理功能

管理员可以管理爬虫的爬取时间，查看爬虫的状态，以及爬虫爬取的数据等等。

(3) 关键字提取功能

管理员可以选择关键字提取的算法，一般默认为 TextRank 算法。

(4) 评论管理功能

对于一些不恰当的评论，管理员可以通过评论管理，对其进行删除，也可以对一些时间不对的评论进行隐藏。

(5) 新闻管理功能

因为爬取的新闻可能存在一些词语上的问题或者显示的问题，这时管理员就可以通过这项功能来修改文章，也可以屏蔽文章，防止一些过激的文章展示给用户。

具体功能如图 3 管理员用例图所示。




图 3 管理员用例图

3.3 性能需求分析

在开发的过程中，软件设计者需要考虑到性能需求，尽可能的设计出高性能的软件系统。

(1) 高并发

需要考虑到高并发的情况，保证在多个用户同时操作的情况下，保证数据不会出错。

(2) 响应速度

在保证页面显示下，需要提高响应速度。对于搜索来说，需要提高搜索后的响应速度，其中包括了数据库查询速度，前端渲染速度以及后端传输速度。

(3) 安全性

需要确保用户的密码安全，管理员的权限以及新闻内容安全，不被其他人修改

3.4 其他需求分析

(1) 保持界面的大方、美观

对于用户来说，页面的显示美观程度是他们选择平台的第一要素。所以在网页设计上，设计出对新用户友好的界面。

(2) 可拓展性

网页设计是一个迭代的过程，要在不断的修改中逐渐完善网站内容。所以软件的可拓展性就变得非常的重要，在后端上，采用了阿里巴巴开发手册中的标准，前端上采用了 ES6 标准，保证了可拓展性。

4 概要设计

4.1 系统结构设计

本系统一共分为三个端，分别是爬虫端，内容处理部分以及系统部分。爬虫部分负责的是爬取新闻网站上的新闻报道内容，进行简单的去重，再放进数据库。而内容处理部分，负责计算新闻正文的内容，把关键字计算并且提取出来。系统部分就分了游客端、用户端以及管理员端。

如图 4 系统功能划分图所示：




图 4 系统功能划分图

4.2 功能模块设计

根据以上的系统结构设计，系统分为了三个部分，先是爬虫部分，爬取到的新闻内容导入数据库中，接着内容处理部分从数据库中读出数据，处理完后再重新导入数据库。最后就是系统部分，网页把爬取到的内容显示在页面上，把处理好的数据也显示在页面上。游客可以浏览新闻内容，用户可以管理自己展示的资料，根据自己喜欢的内容收藏评论新闻。管理员可以对用户的评论进行删除，对用户账号进行关闭等等。

4.2.1 爬虫部分模块

(1) 新闻爬取模块

在爬取新闻内容方面，首先选择的是大型的新闻平台，这里选择的是凤凰网的新闻

报道，他汇聚了网上大型新闻网的新闻内容。通过使用 Scrapy 框架。在凤凰新闻的首页上抓取新闻的简略图、新闻标题、新闻地址、写入字典中，再通过深度爬取，爬取新闻地址内的新闻内容，发布日期，作者。爬取好一篇新闻报道的内容以后，写入数据库中。

由于首页中的新闻报道数量有空，平台用到了 Ajax 技术加载新闻报道。破解 Ajax 的连接，直接向服务器请求，返回一段时间内的新闻，再根据上述爬取新闻报道的步骤一个个爬取新闻。这样就能做到在一段时间内爬取一百篇以上的新闻内容。

(2) 新闻查看模块

爬取到的数据在数据库中可能存在着相同的内容，所以在获得数据以后，先从数据库中查询是否存在相同的内容，做到简单的去重。

(3) 定时更新模块

在爬虫中设定了每四小时，爬虫自动爬取一次新闻。由于 Scrapy 框架较为消耗系统资源，所以定时四个小时既可以获得最新的新闻，也可以减少系统资源的消耗。

4.2.2 内容处理部分

首先是从数据库中导出没有被处理过的新闻报道，对新闻报道进行分词处理，这一部分用到了 TextRank 算法，对词语进行统计排列，列出前 N 个关键词，这里选择了前 5 个关键词。再把关键词导入到数据库中

4.2.3 系统部分

(1) 新闻展示模块

这里分为两个模块，一是简要展示模块，主要是在首页展示，展示的是最新的新闻报道内容，展示内容包括了新闻标题，新闻简略图，发稿时间，原作者以及该篇内容的关键字。以上内容可以让用户大概了解一篇新闻的内容，如果用户对该篇新闻感兴趣，可以通过链接点击到详情页查看。

二是新闻详情展示模块。用户可以通过点击新闻简要展示连接进入到新闻详情展示页面，除了有简要展示模块的内容外，还有新闻正文内容，新闻刊登网站。用户也可以通过点击标题，进入到原新闻网站浏览新闻报道。除此之外，详情页面还包括了其他模块。

最后管理员可以通过后台的新闻管理，修改新闻内容。

(2) 搜索模块

该模块无论是游客还是用户都可以使用。搜索模块主要就是通过用户给出的搜索关键词，搜索出相关度最高的新闻并且显示出来。这里可搜索的内容提供了新闻标题、

新闻作者以及新闻报道的关键字等等。搜索出来的结果是以简要资料展示出来。

(3) 收藏模块

当用户进入了一篇新闻详情页中查看时，如果用户发觉这一篇新闻内容比较优质或者是用户喜爱这一篇新闻报道，用户通过收藏模块，收藏到自己的收藏夹中。这样，当用户想要重新翻出该篇新闻报道时，可以通过自己的收藏夹中找出，而不再需要通过一篇一篇的去查找，方便用户。当然用户通过收藏夹，删除自己的收藏新闻。

(4) 喜爱模块

这个模块不同于收藏模块的一点在于，收藏模块只能用户使用，而喜爱模块包括了游客在内也可以使用。对一篇新闻报道点击喜爱以后，虽然不能像收藏模块一样在收藏夹中找到该篇文章。但是在后台中统计了每一篇新闻报道的喜爱数，排行榜根据喜爱数展示出前几位的新闻。

(5) 评论模块

由于新闻报道五花八门，每一篇新闻报道带给用户不同的感受，所以提供了评论模块，方便用户各抒己见，同时，用户可以看到其他其他用户的评论。形成一个讨论平台。这样的平台不仅是用来看新闻报道，还能用于交流。

因为存在一些人的评论不恰当，会影响其他人的观看感受，但是发表这个评论的用户没有察觉到。这时候就需要管理员通过删除或者隐藏评论。

(6) 管理个人资料模块

在这个新闻管理平台上，每个都可以各抒己见，当遇到相同观点的人的时候，人们可以通过点击其他用户的个人资料来认识其他用户。这时，用户可以展示一些资料给其他用户浏览。所以需要修改个人资料模块。这一部分主要是修改自己的用户名、个性签名等。同时，为了保障用户的安全，也提供了修改密码，修改邮箱的功能，让用户保护自己的账户安全。

(7) 爬虫管理模块

因为各个新闻网站是动态的，所以会存在着页面的更换，或者网站加入反爬系统，这样就会导致爬虫爬取不到数据，所以这个时候，管理员就需要通过观察爬虫的爬取数据判断爬虫模块是否存在问题。以及在一些特殊时间，会存在新闻报道集中发稿，这个时候就需要调整爬虫的爬取时间以获取最新的新闻资料。

(8) 排行榜模块

在排行榜中，通过用户的喜爱、收藏、评论数量，来展示排行榜，同时，排行榜也

有会展示各个新闻报道提出关键字的次数，降序排列，展示出来。

4.3 数据库设计

4.3.1 项目实体 E-R 图

在爬虫部分抽象出来的实体有 1 个:新闻实体。在新闻平台抽象出来的实体有以下:分别为收藏实体,评论实体,评论新闻实体,关键字实体,每篇新闻关键字实体,用户实体,一共 8 个实体。系统 E-R 图如图 5:




图 5 系统 E-R 图

(1) 新闻实体

新闻实体就是爬虫从网站爬取到的信息。实体字段包括了新闻 id, 原地址链接, 新闻标题, 作者, 位置, 来源网, 发稿日期, 封面链接, 新闻内容。

(2) 用户实体

用户实体用于记录用户的信息, 其中包括了用户 id, 用户名, 盐, 用户电子邮箱,

密码，状态，创建日期，更新日期，最后一次登录，用户角色，用户评论数，个性签名。

(3) 收藏实体

收藏实体用于记录用户收藏的新闻。其中包括了收藏 id，用户 id，新闻标志号。

(4) 新闻展示实体

新闻展示实体主要是把爬取到的新闻展示到页面上，其中包括了每一篇的 id，对应爬取的新闻 id，评论数，状态，喜爱数。

(5) 评论实体

评论实体用于记录用户对新闻报道的评论，其中包括了评论 id，用户 id，新闻 id，评论内容，状态，创建时间，更新时间，喜爱数。

(6) 关键字实体

关键字实体用于记录分析新闻内容后得出的关键字，其中包括了关键字 id，关键字，出现次数。

(7) 新闻关键字实体

新闻关键字实体用于记录每一篇新闻出现的前 5 位关键字，其中包括了每一条数据的 id，文章 id，关键字，等级，频率。

(8) 角色实体

角色实体主要是记录了用户的角色，用户的角色决定了用户的管理权限，包括了 id，角色名，角色中文名。

4.3.2 数据库表设计

系统中用到了 8 个数据表，其中包括了新闻表、新闻展示表、收藏表、用户表、关键字表、新闻关键字表、评论表、角色表。

(1) 数据库表汇总

表 1 数据库表汇总

名称	代码	注释
新闻表	new	记录爬取的新闻信息
新闻展示表	new_post	记录新闻展示信息
用户表	news_uer	记录用户信息
收藏表	new_collection	记录收藏信息
评论表	new_comment	记录每一篇新闻的评论
关键字表	new_keyword	记录关键字

新闻关键字表	new_keyword_post	记录每一篇新闻报道的关键字
角色表	news_user_role	记录用户角色

以上就是系统中使用到的 7 个表。

(2) 新闻表

该表用于存储从各大新闻网站中爬取到的新闻信息。如表 2 所示。

表 2 新闻表

名称	代码	外键	主键	数据类型
新闻编号	nid	否	是	char(32)
原链接	link	否	否	varchar(255)
新闻标题	title	否	否	varchar(255)
作者	author	否	否	varchar(20)
优先级	priority	否	否	tinyint(4)
来源	source	否	否	varchar(20)
发稿日期	newdate	否	否	datetime
封面	cover	否	否	Varhcar(255)
新闻内容	text	否	否	text

(3) 新闻展示表

用于在详情页面中展示新闻内容，如表 3 所示。

表 3 新闻展示

名称	代码	外键	主键	数据类型
新闻展示编号	id	否	是	int(10)
新闻编号	nid	是	否	char(32)
状态	status	否	否	tinyint(4)
喜爱数	like	否	否	int(10)
评论	comments	否	否	int(10)

(4) 评论表

用于在详情页面中，记录对该篇新闻的评论，如表 4 所示。

表 4 评论表

名称	代码	外键	主键	数据类型
评论编号	id	否	是	int(10)
新闻编号	nid	是	否	char(32)
用户编号	uid	是	否	int(10)
评论内容	content	否	否	text
状态	state	否	否	tinyint(1)
创建日期	created	否	否	datetime
更新日期	update	否	否	datetime
喜爱数	like	否	否	int(10)

(5) 收藏表

用于记录用户收藏的新闻报道，如表 5 所示。

表 5 收藏表

名称	代码	外键	主键	数据类型
收藏编号	id	否	是	int(10)
新闻编号	nid	是	否	char(32)
用户编号	uid	是	否	int(10)

(6) 关键词表

用于记录新闻中计算出来的关键词，如表 6 所示。

表 6 关键词表

名称	代码	外键	主键	数据类型
关键词编号	id	否	是	int(10)
关键词	keyword	否	否	varchar(64)
出现次数	count	否	否	int(10)

(7) 用户表

用于记录登录平台的用户，如表 7 所示。

表 7 用户表

名称	代码	外键	主键	数据类型
用户编号	id	否	是	int(10)
用户名	username	否	否	varchar(64)
电子邮箱	email	否	否	varhcar(64)
盐	salt	否	否	varhcar(64)
状态	state	否	否	tinyint(1)
创建日期	created	否	否	datetime
更新日期	update	否	否	datetime
最后登录时间	last_login	否	否	datetime
用户角色	role_id	否	否	int(10)
评论数	comments	否	否	int(10)
个性签名	signature	否	否	varchar(140)

(8) 新闻关键字表

用于在记录每一篇新闻中出现的关键字，如表 8 所示。

表 8 新闻关键字表

名称	代码	外键	主键	数据类型
新闻关键字编号	id	否	是	int(10)
新闻编号	nid	是	否	char(32)
关键字	keyword	否	否	varhcar(64)
等级	rank	否	否	int(10)
频率	frequency	否	否	float

(9) 角色表

用于记录用户角色，为用户区分权限，其中角色中文名用作于显示，如表 9 所示。

表 9 角色表

名称	代码	外键	主键	数据类型
角色编号	id	否	是	int(10)
角色名	name	否	否	varchar(32)

角色中文名	name_zh	否	否	varhcar(32)
-------	---------	---	---	-------------

5 详细设计

5.1 新闻爬虫详细设计

5.1.1 新闻内容爬取详细设计

爬取网页的第一步就是分析网页页面的内容。提取新闻信息分为两步，第一步是将新闻平台首页的新闻分类，分类标准以新闻报道在平台位置作为标准，分为两类，第一类是在页面置顶的新闻，这些新闻一般属于当日的头条新闻。第二类是滚动的普通新闻。

爬取一篇完整的新闻内容需要分析页面内容，提取数据。一般来说，首页的新闻只包括了新闻标题、新闻作者、发稿日期，内容地址。得到的内容是不完整的，所以需要把爬取到的数据保存数据到字典中，将字典传递给下一层程序处理，也就是需要深入二级页面爬取新闻内容。得到新闻内容，创作时间等等，接着交给 PipeLine 组件处理。

各大新闻平台为了保持首页的整洁，所以首页显示的普通新闻是有限的。通过分析 URL，获得更多的普通新闻可以通过构造 Ajax 请求获得。获取到普通新闻的简略资料后。后续的处理步骤就如同上面处理普通新闻的步骤一样。 时序图如图 6 所示。




图 6 新闻内容时序图

5.1.2 爬虫处理数据详细设计

由于爬虫系统设计方面采用 Scrapy 框架进行信息的爬取。Scrapy 内部实现了多种复杂的操作^[6]。使用前设定一定的参数，比如爬取每个页面的时间间隔等等。Scrapy 需要编写三个部分，第一个部分就是处理页面部分也就是爬虫（Spider），这个部分是爬取内容的主要核心。第二个部分就是管道（Item Pipeline），这个部分是处理从爬虫传过来的数据。在执行爬虫前，管道还需要提前连接数据库，数据库会返回连接的情况。根据数据库中数据的约定，在管道这部分将修改一些数据的格式。处理完数据以后，将数据写入数据库。由于存在爬取相同的新闻内容，在写入数据库前，管道需要查询数据库中是否存在同样的新闻内容。无论是否插入数据，管道都需要给前台（用户）返回数据，查看是否成功。如图 7 爬虫处理时序图。




图 7 爬虫处理时序图

5.2 关键字提取流程

爬取到新闻以后。需要对新闻内容进行处理，需要提取出新闻内容中的关键字，这里使用的是 TextRank 算法。公式如下：

$$WS(V_i) = (1 - d) + d * \sum_{V_j \in In(V_i)} \frac{w_{ji}}{\sum_{V_k \in Out(V_j)} w_{jk}} WS(V_j)$$

参数：

- (1) $WS(V_i)$ 表示 v_i 的 rank 值。
- (2) $In(V_i)$ 表示节点 V_i 的前驱节点集合。
- (3) w_{ij} 表示两个节点之间边的连接的重要程度
- (4) $Out(V_j)$ 表示节点 V_j 的后继节点集合。
- (5) d 为 damping factor 用于做平滑。

处理流程如下：

- (1) 对新闻内容进行处理，去除停用词、图片地址、标点符号、语气助词。
- (2) 用 Jieba 组件对新闻进行完整的句子分割。
- (3) 分割出来的句子进行词语的分割，把分割的词 i 以及在窗口范围内的词 j 作为键，以及他们出现的次数作为值放入词典中。
- (4) 依次遍历词典中的每个元素，将词 i ，词 j 作为一条边起始点和终止点，共同出现的次数作为边的权重。
- (5) 根据边的相连关系，构建矩阵，计算矩阵内边的关系。
- (6) 进行归一化处理。
- (7) 提取出前 5 个权值最大的关键词。

处理完关键字后，将关键字以及相关关联的新闻报道写入数据库中。时序图如图 8。




图 8 关键字处理时序图

5.3 用户登录注册操作详细设计

这一部分主要展示的是用户登录、注册以及在系统内操作的详情设计

5.3.1 用户登录详细设计

用户登录一共分为三个部分，分为前端、后端以及数据库。用户在前端中输入用户名和用户密码。前端通过反向代理传给后端处理。后端接收到前端信息后，首先向数据库查询，找出是否存在该用户名。如果存在则验证账户是否被禁用，如果没有被禁用，则向数据库验证密码。如果密码没错，使用 Token 保存登录信息。最后向前端发送信息，前端如果成功登录，则跳转到首页，否则返回登录失败信息，同时前端也储存用户信息到本地，以便再次打开网站时，不用重新登录。其时序图如图 9。




图 9 用户登录时序图

5.3.2 用户注册详细设计

用户注册，在前端页面上输入用户名、用户密码以及邮箱地址，通过反向代理传给后端。后端接收到用户注册信息以后，先检查数据库中是否存在相同的用户名。如果存在就返回错误信息，否则就生成“盐”，“盐”用于密码的加密，利用盐和用户输入的密码，进行两次 Hash 操作。将用户注册信息传入到数据库以后，返回信息给前端。如果注册成功跳转到登录见面，注册失败显示错误信息。用户注册时序图如图 10 所示：




图 10 用户注册时序图

5.3.3 用户操作详细设计

新闻展示及相关操作。

访问首页，映入眼帘的就是新闻展示。新闻展示是在加载首页时一并向后端索要数据。通过后端访问数据库，按照时间顺序，以及新闻报道在原平台的位置，返回新闻简要内容。用户通过点击新闻标题跳转到新闻详细内容。进入了新闻详情页前，系统会查询用户是否收藏过该篇新闻，并显示出来，用户在详情页中可以选择收藏或者点击喜爱。用户也可以评论。另外，所有的收藏、评论都可以在个人中心看到，并且可以对收藏、评论进行修改或删除。时序图如图 11。




图 11 用户操作时序图

6 系统实现

6.1 软件开发说明

6.1.1 核心开发技术介绍

(1) Spring Boot

Spring Boot 在保证原来 Spring 中两大优秀的特性（IOC 和 AOP）的前提下^[7]。在 Spring Boot 框架出来前，一般使用 SSH 或者 SSM 框架，但是他们都有着致命的缺点，就是框架过多，需要配置的参数也很多。Spring Boot 本身并不是一个框架，而是由各种框架堆积起来的约定使用方式，以“约定大于配置”为主，简化构建 Spring 程序的繁琐的手续。并且 Spring Boot 的快速开发也符合了微服务结构的应用。

(2) Vue.js

Vue 是一套用于构建用户界面的渐进式 JavaScript 框架^[8]。与其它大型框架不同的是，它具有一套完备的用户界面构建模式且是呈现出渐进式的框架结构^[9]。Vue 的核心库只关注视图层，他是在 HTML、CSS、JavaScript 的基础上进行的二次开发，有基本的 Web 前端知识都可以快速的上手 Vue.js。

(3) MySQL

MySQL 数据库作为一款开源的关系型数据库系统^[11]，由瑞典 MySQLAB 公司开发，属于 Oracle 旗下产品。MySQL 是最流行的关系型数据库管理系统之一。作为一款开源软件，他为各种编程语言提供了 API，适用的场景非常多。

(4) Scrapy

Scrapy 是使用 Python 编写的爬虫应用框架程序^[12]，用于抓取 web 站点并从页面中提取结构化的数据。Scrapy 用途广泛，可以用于数据挖掘、监测和自动化测试。

(5) Jieba 分词

汉语以字作为最小单位的特点，使得所有基于中文的自然语言处理中，都必须在汉字字符串组成的句子被准确识别成词序列之后，才能进一步地展开^[13]。Jieba 目前最好的 Python 中文分词组件，他是一款开源的组件。

(6) TextRank

TextRank^[14]由 Mihalcea 与 Tarau 于 EMNLP'04 提出来，其思想非常简单：通过词之间的相邻关系构建网络，然后用 PageRank^[15]迭代计算每个节点的 rank 值，排序 rank 值即可得到关键词。

6.1.2 项目技术架构

本新闻热点平台后端是基于 Spring boot 框架进行开发，使用的是 MySQL 数据库。通过后端通过 MyBatis 框架连接数据库。爬虫端是用 Python 语言的 Scrapy 框架，简化了开发难度。在处理新闻内容关键字算法上使用了 TextRank 算法。前端方面，使用的是 Vue.js 框架。使用了 Element 工具，美化网站 UI。

6.2 操作系统界面和功能实现

6.2.1 首页界面

首页分为了三个部分。如图 12。第一个部分是导航栏，导航栏的作用是帮助用户快速转换页面，比如在观看新闻内容，可以通过导航栏快速回到首页。同时用户可以通过导航栏跳转到排行榜和管理中心（也就是修改个人资料）。回到首页。首页由两个大部分组成。第一个部分就是关键字的排行榜，主要就是显示所有新闻的 Top10 关键字。另外

一部分就是由搜索栏和新闻简要报道组成。

接下来就是新闻简要的部分，这里展示的是新闻的简略图、新闻标题、发稿日期，以及该篇新闻的计算出来的 Top5 关键字。把一篇新闻报道大致的内容清晰展示在用户的眼中。用户通过点击标题，进入首页，查看详细内容。

因为首页加载的新闻简略报道设定为 10 篇，用户通过末尾的“加载更多”按键能够获取更多的新闻。



图 12 首页

搜索栏根据用户给出的关键字搜索新闻，选择标题、作者或者关键字。按照时结果的相关性以及时间降序展示给用户观看。展示结果如图 13。



图 13 搜索结果

6.2.2 新闻详情页

当用户点击首页的链接进入到新闻详情页后，如图 14。用户可以看到该篇新闻更多的内容。比如新闻的来源网，也就是发稿的网站。最重要的是查看新闻内容，用户可以根据自己兴趣，决定是否收藏该篇新闻，系统为用户提供了收藏按键，点击以后就会收藏在用户的收藏菜单中。以供用户日后再次浏览。当然，如果用户已经收藏了该篇文章，也可以通过再次点击按钮，取消收藏。文章也就会从用户收藏菜单中删去。同时，如果用户喜欢该篇新闻可以点击喜爱按钮（红色爱心），系统会根据新闻的喜爱数，在排行榜上显示前 10 个喜爱数最多新闻，给其他用户看到哪些新闻是用户最爱。同时，系统也会根据用户的收藏数，在排行榜中显示出前 10 位收藏数最多的新闻。另外，推荐系统会根据用户的收藏，推荐类似的新闻给用户。最后，如果用户想查看更多的细节，可以通过点击标题，去到原网站查看原新闻。

刑拘！北京一女子坐拥多套房产 专偷小区快递

作者:环球网 时间:2020-04-07 16:00:10 来源:凤凰网 ☐ 收藏文章 

“白天上班，来不及拿快递，晚上回来再找，就不见了。”3月14日，朝阳公安分局接群众报警称，其从网上购买的外卖在六里屯某小区无接触快递存放点被盗。丢失的快递基本都是附近居民网购的蔬菜、蛋奶、牛肉和海鲜类的食品。
https://x0.ifengimg.com/res/2020/808967046388C23649FFF5D397AAF6206F80CADE_size68_w6
接报后，朝阳公安分局六里屯派出所迅速开展调查，民警在调查中发现，除该案件外，小区还有两起外卖被盗情况，违法人员均为女性，且体貌特征相似，基本确定系同一人所为。通过小区监控视频查看，嫌疑人到小区存放点附近，先找到自己要取的快递，然后趁工作人员不注意，将其他人的快递一并拿走，再从小区大门口抱着大包小包，从容地走进去。随后，民警对案发小区及周边多个快递存放点进行大量走访，于3月16日将该女子成功抓获。经审查，该女子为张某（女，36岁），系该小区居民，民警在其家中起获多份被盗外卖及包装盒，冰箱内还有多种未来得及食用的牛肉和海鲜，其对多次盗窃他人外卖、快递等物品违法犯罪事实供认不讳。据该小区附近居民反映，张某家境优越，父母经营公司，仅在六里屯附近就有两套房产。记者了解，在事发小区附近，目前房价基本保持在5万只6.5万一平方米的价格。而张某却表示，偷小区附近快递“只是为了贪些小便宜。”最终，嫌疑人张某因涉嫌盗窃罪被朝阳警方依法采取刑事强制措施。文/王浩雄 北京青年报记者 叶婉

图 14 新闻详情页

用户可以通过在新闻下面的评论功能，对新闻进行评论，当前用户也可以看到其他用户的评论。

A screenshot of a news comment form. It features a text input field with the placeholder text '请输入内容' (Please enter content). Above this field, there is a preview area showing the text 'admin' and '没想到欧洲的病例居然这么多了' (I didn't expect the number of cases in Europe to be so high). To the right of the input field is a blue button labeled '提交' (Submit).

图 15 新闻评论

6.2.3 登录界面

用户在登录界面中输入账号和密码，如果验证成功则跳转到首页，否则输出错误信息。如果用户选择不登录，则有些功能是不可以使用的，比如修改个人信息等等。登录界面如图 15。

A screenshot of a login form titled '热点新闻网站登录' (Hot News Website Login). It contains two input fields: '账号' (Account) and '密码' (Password). Below these fields is a dark grey button labeled '登录' (Login).

图 15 登录见面

6.2.4 注册界面

注册界面类似登录界面，注册界面则需要输入用户名，输入两次相同的密码，以防出错。以及需要输入电子邮箱，用于找回密码。如果注册成功则跳转到登录见面。否则

显示错误信息。

6.3 个人界面

6.3.1 个人资料

用户可以通过个人资料了解到个人注册的信息，其中包括了用户名，注册时使用的邮箱，创建的时间以及最后一次登录的时间。并且用户可以改变自己的个人签名，让其他用户看到你的个性签名。同样，当前用户也可看到其他用户的个性签名，如图 16。



用户名	admin
邮箱	skytrc@163.com
创建时间	2020-03-29 02:13:50
最后一次登录	2020-03-29 02:13:50
个性签名	

图 16 个人资料

6.3.2 评论列表

用户可以通过评论列表，看到自己之前所评论过的新闻标题以及评论内容，当然通过删除按钮删除评论。如图 17。



标题：西昌森林火灾牺牲扑火队员照片公布 评论内容：1231 时间：2020-04-03 02:54:11 删除
标题：刑拘！北京一女子坐拥多套房产 专偷小区快递 评论内容：23 时间：2020-04-07 17:21:51 删除

图 17 评论列表

6.3.3 收藏列表

如同评论列表，收藏列表就是展示自己收藏过的新闻，用户点击标题就可以查看新

闻的详细内容，也可以通过删除按钮删除该收藏如图 18。



图 18 收藏列表

6.4 管理员界面

管理界面是根据用户角色动态加载的，比如有些管理员只有评论管理的权限，这时，菜单会根据你的权限动态生成。防止无关触碰到相关的内容。

6.4.1 用户管理界面

在用户管理中，只有拥有最高级别权限的管理人员才能管理用户。这个模块包括了显示所有的用户信息，包括了用户名，Email，登录日期等等，按照信息排序。并且能够分配管理权限。比如可以分配给其他管理员管理评论的权限或者管理新闻的权限等等。最后，还有一个功能就是对用户进行冻结或者是解冻。如果有些用户评论或者发言违反了规定，可以对其进行冻结。如图 19。

最后登录日期	评论数	用户角色	状态	操作
2020-04-14 02:13:50	0	1	正常	<button>解冻</button> <button>冻结</button>
	0	4	正常	<button>解冻</button> <button>冻结</button>
	0	4	正常	<button>解冻</button> <button>冻结</button>
	0	4	正常	<button>解冻</button> <button>冻结</button>

图 19 用户管理界面

6.4.2 评论管理

在评论管理中，如同用户管理界面一样，需要有对应权限的管理员才能进入到这个页面中。类似的，评论管理可以看到发表评论的用户，文章，发表时间以及内容。为了让社区更能好的运行，也会有封禁功能，防止一些过激的评论出现，如图 20。

ID	用户名	标题	内容	发表日期
4	admin	西昌森林火灾牺牲扑火队员 照片公布	1231	2020-04-03 02
5	admin	刑拘！北京一女子坐拥多套 房产 专偷小区快递	23	2020-04-07 17

图 20 评论管理界面

6.4.3 新闻管理

新闻管理是一个比较复杂的内容，因为存在大量的数据，所以在这个模块，增加了搜索功能和分页功能，为了能更快的检索到所要的文章信息。另外类似上面的功能，管理员可以通过界面查看到显示的新闻信息，也可以操作，修改文章信息等等。当然也有冻结功能，冻结以后用户就无法在检索和浏览到该篇文章。如图 21。

作者	发表日期	评论数	喜爱数	状态	输入关键字搜索
中国新闻网	2020-04-15 19:57:49	0	0	正常	解冻 冻结

图 20 新闻管理界面

另外，通过分页条，管理员可以看到一共存在多少新闻，并且通过分页条可以分批次查询数据库，减少数据库的负担。如图 22。

澎湃新闻	2020-04-15 18:49:51	0	0	正常	解冻 冻结
共 1926 条 < 1 2 3 4 5 6 ... 193 >					

图 21 分页条

7 结语

新闻热点平台的实现，主要是通过爬取新闻网站上的新闻，爬取大型新闻网站中的新闻报道，相比自媒体发出来的新闻报道，大型新闻网站中的新闻报道解决了时效问题以及新闻可能存在虚假的问题。接着，通过利用 TextRank 算法，计算爬取到的新闻内容，将新闻内容的关键字提取出来，展示到用户的页面上。用户不仅能够通过标题，了解文章的大致内容，也提供另一种了解新闻内容的方式。通过建立新闻平台，将爬取到的新闻和处理好的关键字展示出来，使得各大用户了解最新的资讯动态。并且提供了评论和收藏功能，让用户对感兴趣的新闻发表评论和收藏等。设置了排行榜，让用户了解当下最热门的新闻以及最近新闻中，哪一些关键词出现的比较频繁，了解最近报道的趋势。

本次设计是在 Window10 环境下开发，使用了前后端分离的技术方案，对系统开发解耦。在前端，使用 Vue.js 框架。后端上使用 Spring Boot 框架。而在数据库上，使用 MySQL，在安全方面，为了防止用户伪造数据，使用了 Shiro 框架，保证用户登录的安全。在爬虫的技术上，使用的是 Scrapy 框架，这个框架简化了开发，使开发人员更加专注于业务。在写毕业设计的同时，不断的查找各种资料，从一开始对技术的迷茫，到后面的逐渐熟悉如何使用框架、技术。不断的提高我解决问题的能力，这是对我大学四年来学习的一次总结，如何从一无所知到熟练运用。

同时本系统还有很多的修改空间，比如在关键词的提取中，可以使用机器学习或者深度学习的算法，识别上下文，增加关键字提取的精度等等。另外，爬取的内容也没有分类，可以通过聚类算法，将所有的新闻分类。在社交的功能上，还有很多地方没有做好，比如评论之间的回复，新闻的分享等等。

参 考 文 献

- [1] 王嘉璇.新媒体传播平台上的网络新闻分析[J].记者摇篮,2020(03):145-146.
- [2] 刘晖,石倩.基于网络爬虫的新闻网站自动生成系统的设计与实现[J].电子技术与软件工程,2019(13):18-19.
- [3] 牛萍. TF-IDF 与规则结合的中文关键词自动抽取研究[D].大连理工大学,2015.
- [4] 童昱强. 基于数据挖掘的网络新闻热点发现系统设计与实现[D].北京邮电大学,2019.
- [5] 李慧敏,孙佳亮.论爬虫抓取数据行为的法律边界[J].电子知识产权,2018(12):58-67.
- [6] 杨君. 基于 Scrapy 技术的数据采集系统的设计与实现[D].南京邮电大学,2018.
- [7] 王梓任. 基于 Spring Boot 的新闻采编发平台的研究与实现[D].北京邮电大学,2019.
- [8] 麦冬,陈涛,梁宗湾.轻量级响应式框架 Vue.js 应用分析[J].信息与电脑(理论版),2017(07):58-59.
- [9] 陈岩.轻量级响应式框架 Vue.js 应用分析[J].中国管理信息化,2018,21(03):181-183.
- [10] 沈蕴梅.基于 PHP+MySQL 的网上购物系统的设计与开发[J].计算机时代,2018(12):22-24.
- [11] 范开勇,陈宇收.MySQL 数据库性能优化研究[J].中国新通信,2019,21(01):57.
- [12] 马联帅. 基于 Scrapy 的分布式网络新闻抓取系统设计与实现[D].西安电子科技大学,2015.
- [13] 蒋卫丽,陈振华,邵党国,马磊,相艳,郑娜,余正涛.基于领域词典的动态规划分词算法[J].南京理工大学学报,2019,43(01):63-71.
- [14] 卢佳伟,陈玮,尹钟.融合 TextRank 算法的中文短文本相似度计算[J/OL].电子科技,2020(10):1-8[2020-04-12].<http://sso.gzlib.org.cn/interlibSSO/goto/75/=jmr9bmjh9mds/kcms/detail/61.1291.TN.20191122.1644.032.html>.
- [15] 景楠,王建霞,许皓,卞亦文.基于用户社会关系的社交网络好友推荐算法研究[J].中国管理科学,2017,25(03):164-171.

致 谢

首先，我要特别感谢我的导师肖爱平导师和伍碧林导师。感谢导师在我完成毕业论文的过程中对我的认真指导和解疑释惑。感谢老师给我的毕业设计提出宝贵指导。老师以他专业的眼光，洞察到我设计中不足的地方以及错过的细节。在我对毕业设计感到迷茫时，通过老师的悉心教导，慢慢的拨开我疑惑。也感谢大学四年来教过我的老师，没有他们的教导，没有基础知识的积累，我也不可能一步一步的写出这篇毕业设计。

感谢家人和朋友，在我失落和不知所措时，给我提供了一如既往的帮助和鼓励。在面临抉择时，给我提供了可靠的意见。最后感谢同学。在我遇到技术困难时，与我一起讨论难题，帮助我度过难关。

最后，引用一句名言：“凡是过往，皆为序章”。希望这篇毕业设计不是结束，而是一个美好的开始。

仲恺农业工程学院

本科毕业论文(设计)成绩评定表

学 院	计算科学学院	专业班级	信息与计算科学 162 班
姓 名	周广锋	学 号	201621314232
毕业论文(设计)题目	基于网络爬虫的热点话题网站设计与实现		
校内指导教师姓名	肖爱平	职务/职称	实验师
校外指导教师姓名	伍碧林	职务/职称	工程师
指导教师评语及评分： 该生毕业论文工作期间态度认真，积极主动联系老师，能按时提交各项资料，论文“基于网络爬虫的热点话题网站设计与实现”选题有一定的实用性，项目通过 Python 中的 Scrapy 框架，爬取各大新闻网站的新闻资讯，存入 MySQL 数据库中。通过 TextRank 算法，对新闻内容进行关键字的提取。使用 Spring Boot 框架作为后端框架，Vue.js 作为前端框架，把新闻内容以及其关键字展现在网页上。软件设计符合软件工程规范，软件相关理论准备充实、方法得当，操作方便、灵活。论文格式基本规范、结构合理、语言文字表达清晰。资料收集能力较好，参考文献时效性较强。同意参加答辩。 评分为： 92 签名：肖爱平 2020 年 4 月 22 日			
论文“基于网络爬虫的热点话题网站设计与实现”选题现实意义较强，软件设计具有一定的应用价值，理论准备充实、方法得当，界面方便、友好。论文的结构比较清晰、语言文字表达通顺，参考文献的引用充分合理。文章有一定的个人见解，文题相符，符合科学论文的一般规范，工作量符合本科毕业论文的要求。 评分为： 96 签名：杨志伟 2020 年 4 月 25 日			

答辩记录:

问题 1: 关键字是怎么提取的

答: 通过对每一篇新闻正文分析得到的。对正文进行分词处理, 把一个句子分成多个词语, 在对词语进行统计, 我这里是选取 Top5 个出现频率最高的词语显示出来。

问题 2: 关键字的提取是通过对一篇报道内容的提取还是基于全部报道的提取。

答: 只是对每一篇的新闻内容进行处理, 每次处理不涉及到其他的文章, 处理后就存储在数据库中

问题 3: 如果只是基于一篇报道的提取, 如果有一篇垃圾新闻重复了很多个字, 他提取出来的关键字怎么办

答: 对, 有这个可能。我没有考虑到, 我知道考虑到对一篇文章的处理。如果是处理垃圾文章, 就需要一个大型的语料库处理, 需要训练一个语料库出来

答辩秘书:

赖燕玉

2020 年 5 月 9 日

答辩小组评价意见及评分:

该论文选题合理, 格式规范, 内容满足本科论文要求, 相关软件工作量饱满, 符合本科毕业设计的要求, 回答问题思路清晰、准确。同意通过答辩。

评分为: 95

答辩组长:

侯超钩

2020 年 5 月 9 日

论文(设计)成绩	指导老师 (40%)		评阅老师 (20%)		答辩小组 (40%)		总评分	等级
	原始分	折算分	原始分	折算分	原始分	折算分		
	92	36.5	96	19.2	95	38	94	优秀
学院答辩领导小组(委员会)审核意见	根据指导老师、评阅老师和答辩小组的评分, 同意该生的毕业论文成绩评定为 (优秀) 等次。 签章: 2020 年 5 月 30 日							

注: 1、论文(设计)成绩一栏中, 折算分分别由指导老师 (40%)、评阅老师 (20%)、答辩小组 (40%) 给出的原始分乘以各自百分比例所得。总评分由折算分相加所得。

2、“等级”: 90 分以上为“优秀”、80—89 分为“良好”、70—79 分为“中等”、60—69 分为“及格”、59 分以下为“不及格”。